

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO

Beatriz Torres Sailer
Brener Leopoldino
Bruna Carolina Miranda da Silva
Rafael Matheus Padilha
Thayara Akemi Murakami Catan

**Aprendizado de máquina aplicado à série municipal de COVID-19 no
Estado de São Paulo: agrupamento de municípios e avaliação retrospectiva
de alertas**

São José do Rio Preto - SP
2026
UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO

**Aprendizado de máquina aplicado à série municipal de COVID-19 no
Estado de São Paulo: agrupamento de municípios e avaliação retrospectiva
de alertas**

Relatório Técnico-Científico apresentado na
disciplina de Projeto Integrador em
Computação IV (PJI410) para os cursos de
Bacharelado em Tecnologia da Informação –
Ciência de Dados e de Bacharelado em
Engenharia da Computação da Universidade
Virtual do Estado de São Paulo (UNIVESP),
sob a orientação de Fernanda Viviani
Reggiani.

São José do Rio Preto - SP
2026

CATAN, Thayara Akemi Murakami; LEOPOLDINO, Brener; PADILHA, Rafael Matheus; SAILER, Beatriz Torres; SILVA, Bruna Carolina Miranda da. Aprendizado de máquina aplicado à série municipal de COVID-19 no Estado de São Paulo: agrupamento de municípios e avaliação retrospectiva de alertas 33. Relatório Técnico-Científico. Bacharelado em Tecnologia da Informação – Ciência de Dados e Bacharelado em Engenharia da Computação. Universidade Virtual do Estado de São Paulo. Orientadora: Fernanda Viviani Reggiani. Polo São José do Rio Preto, 2026.

RESUMO

A detecção tardia de aumentos no número de casos limita a resposta dos serviços municipais de saúde. Este relatório apresenta o estágio intermediário do Projeto Integrador em Computação IV, que parte de um painel de visualização feito em edição anterior da disciplina e acrescenta a ele análise de dados em escala e aprendizado de máquina. O objetivo é desenvolver uma aplicação web que agrupe os 645 municípios do Estado de São Paulo pelo perfil de disseminação observado e que avalie, de forma retrospectiva, um método para sinalizar elevações atípicas de casos. Foram usados os dados da série municipal da Fundação Seade, com 880.498 registros diários entre 25 de fevereiro de 2020 e 18 de novembro de 2023. A metodologia combina as etapas ouvir, criar e implementar, propostas pela Univesp, com o modelo CRISP-DM, e compreende pré-processamento, construção de atributos, agrupamento por k-médias e detecção de anomalias por limiar estatístico móvel. Já foram concluídos o diagnóstico da aplicação de partida, a auditoria da base, que identificou 1.363 registros sem população de referência, e os dois modelos, hoje integrados à interface. O coeficiente de silhueta ficou entre 0,230 e 0,273 para k de 2 a 8, o que indica estrutura de agrupamento fraca, e a partição em quatro grupos é apresentada como caracterização exploratória. Com limiar de três desvios-padrão, 94,6% dos 4.307 picos identificados tiveram ao menos um alerta nos 60 dias anteriores, com antecedência mediana de 31 dias, e 5,41% dos dias-município foram sinalizados. Esses valores ainda não foram comparados a uma linha de base aleatória e não permitem afirmar que o método antecipa os picos. As próximas etapas são essa comparação, o tratamento das falhas de notificação e a avaliação com profissionais da área da saúde.

PALAVRAS-CHAVE: Aprendizado de máquina; Detecção de anomalias; Análise de dados em escala; COVID-19; Vigilância epidemiológica.

LISTA DE ILUSTRAÇÕES

FIGURA 1 – NOVOS CASOS DIÁRIOS DE COVID-19 NO ESTADO DE SÃO PAULO (MÉDIA MÓVEL DE 7 DIAS), 2020-2023.....	19
FIGURA 2 – INCIDÊNCIA ACUMULADA E LETALIDADE APARENTE NOS MUNICÍPIOS PAULISTAS, POSIÇÃO EM 18/11/2023.....	20
FIGURA 3 – COEFICIENTE DE SILHUETA SEGUNDO O NÚMERO DE AGRUPAMENTOS.....	21
FIGURA 4 – PERFIL PADRONIZADO DOS GRUPOS NA PARTIÇÃO EXPLORATÓRIA COM $K = 4$	22
FIGURA 5 – ALERTAS DISPARADOS E PICOS IDENTIFICADOS NO MUNICÍPIO DE BAURU, 2020-2023.....	23

LISTA DE QUADROS

QUADRO 1 – LIMITAÇÕES IDENTIFICADAS NA APLICAÇÃO DE PARTIDA E AÇÕES PREVISTAS NO PI IV.....	17
---	----

LISTA DE TABELAS

TABELA 1 – CARACTERIZAÇÃO DO CONJUNTO DE DADOS DADOS_COVID_SP.CSV.....	18
TABELA 2 – CARACTERIZAÇÃO DOS GRUPOS NA PARTIÇÃO EXPLORATÓRIA COM $K = 4$	22
TABELA 3 – DESEMPENHO PRELIMINAR DO DETECTOR DE ANOMALIAS (LIMIAR $Z = 3,0$).....	24
TABELA 4 – SENSIBILIDADE DAS MEDIDAS DE DESEMPENHO AO LIMAR DO DETECTOR.....	24

SUMÁRIO

1 INTRODUÇÃO.....	6
2 DESENVOLVIMENTO.....	8
2.1 OBJETIVOS.....	8
2.2 JUSTIFICATIVA E DELIMITAÇÃO DO PROBLEMA.....	9
2.3 FUNDAMENTAÇÃO TEÓRICA.....	10
2.4 METODOLOGIA.....	12
2.5 RESULTADOS PRELIMINARES: SOLUÇÃO INICIAL.....	16
REFERÊNCIAS.....	26
ANEXOS.....	28
APÊNDICES.....	29

1 INTRODUÇÃO

Para responder a um aumento de casos de uma doença transmissível, o serviço de saúde precisa primeiro perceber esse aumento. Durante a pandemia de COVID-19, a Secretaria de Estado da Saúde de São Paulo, com organização técnica da Fundação Seade, publicou todos os dias os casos e óbitos de cada município (FUNDAÇÃO SEADE, 2023). Os dados são públicos, mas o volume e o detalhamento dificultam a leitura direta. Para notar que um município mudou de comportamento é preciso processar a série e compará-la com o histórico recente desse mesmo município.

O projeto parte de uma aplicação web já existente, que mostra casos e óbitos de COVID-19 no Estado de São Paulo e foi construída com Streamlit, Pandas e Plotly. Ela foi desenvolvida em edição anterior do Projeto Integrador por um dos integrantes do grupo, e seu reaproveitamento segue as condições admitidas pela disciplina. Ao examiná-la, o grupo viu que a aplicação mostra bem o que aconteceu, mas não resume as diferenças entre os 645 municípios paulistas nem indica quando algum deles se afasta do próprio padrão.

A ementa do Projeto Integrador em Computação IV envolve visualização de dados, computação em nuvem, Internet das Coisas e aprendizagem de máquina, com o objetivo de desenvolver análise de dados em larga escala e uma interface para visualizar os resultados (UNIVESP, 2026). Em relação à aplicação de partida, o projeto acrescenta duas coisas: usa a série municipal completa, com 880.498 registros, no lugar de arquivos agregados com cerca de 1,3 mil linhas, e aplica técnicas de aprendizado de máquina para caracterizar padrões e sinalizar desvios.

O objeto de estudo é a série diária de casos confirmados e óbitos por COVID-19 nos municípios paulistas, entre fevereiro de 2020 e novembro de 2023. Sobre ela são aplicadas duas técnicas: aprendizado não supervisionado, para agrupar municípios pelo perfil de disseminação, e detecção de anomalias, para sinalizar elevações atípicas em relação ao comportamento recente de cada município. Como a série está encerrada, o detector é avaliado de forma retrospectiva, comparando os alertas com picos que já ocorreram. O trabalho não faz previsão de casos. Os resultados ficam disponíveis em uma interface interativa, com filtros para o usuário escolher o recorte que quiser.

A escolha do tema levou em conta a aplicação de visualização já construída, que o grupo pode ampliar em vez de começar do zero, e a existência de uma base pública grande o bastante para os requisitos da disciplina. As seções seguintes apresentam os objetivos, a justificativa e a delimitação do problema, a fundamentação teórica, a metodologia e os resultados obtidos até aqui.

2 DESENVOLVIMENTO

2.1 OBJETIVOS

O objetivo geral é desenvolver uma aplicação web interativa que, a partir da série diária de casos e óbitos de COVID-19 dos municípios do Estado de São Paulo, agrupe esses municípios pelo perfil de disseminação observado e avalie, de forma retrospectiva, um método para sinalizar elevações atípicas em relação ao comportamento recente de cada um, como demonstração de um instrumento de apoio à vigilância epidemiológica municipal.

Para alcançá-lo, foram definidos os seguintes objetivos específicos:

- Levantar e consolidar a série histórica municipal de casos e óbitos divulgada pela Fundação Seade, identificando sua estrutura, cobertura e periodicidade;
- Identificar registros inconsistentes, valores atípicos e limitações de cobertura que condicionem a análise;
- Definir um procedimento de pré-processamento reprodutível, que trate as inconsistências encontradas sem descartar informação epidemiologicamente relevante;
- Caracterizar o perfil de disseminação de cada município com indicadores derivados da série e normalizados pela população residente;
- Analisar a similaridade entre os municípios por aprendizado não supervisionado, verificando se existem agrupamentos bem definidos e qual partição é mais adequada à interpretação;
- Avaliar retrospectivamente um método de detecção de anomalias, medindo a proporção de picos precedidos por alerta, a antecedência dos alertas e a proporção de alertas não seguidos de pico, em comparação com uma linha de base aleatória;
- Desenvolver interface web interativa que permita consultar agrupamentos e alertas por município, grupo e período;

- Verificar a adequação da solução junto a profissionais da área da saúde, prioritariamente de secretarias municipais, coletando devolutivas para aprimorar a versão final.

2.2 JUSTIFICATIVA E DELIMITAÇÃO DO PROBLEMA

A pergunta que orienta o trabalho é: de que modo técnicas de aprendizado de máquina aplicadas à série histórica municipal da COVID-19 no Estado de São Paulo podem agrupar municípios por padrão de disseminação e sinalizar elevações atípicas de casos antes dos picos, de maneira compreensível para gestores municipais de saúde?

Os registros municipais de COVID-19 são públicos e detalhados, mas, sem tratamento computacional, ajudam pouco quem precisa decidir. Um instrumento que resuma o histórico de um município, o compare com municípios parecidos e avise quando ele se afasta do próprio padrão pode apoiar o planejamento local da vigilância. Como a série da COVID-19 está encerrada, a contribuição deste projeto é demonstrar e avaliar o método sobre dados reais. O uso prático depende de aplicá-lo a séries ainda em atualização, como as de outros agravos de notificação, possibilidade indicada aqui como continuidade do trabalho.

Do lado acadêmico, o projeto reúne os três eixos da ementa da disciplina, que são análise de dados em escala, aprendizado de máquina e visualização interativa, sobre dados públicos e auditáveis. Qualquer pessoa pode conferir os resultados. A reutilização desses dados se apoia no princípio da transparência ativa da Lei de Acesso à Informação (BRASIL, 2011).

A contribuição local prevista é disponibilizar a aplicação e o código, em repositório público, às secretarias municipais de saúde dos municípios de origem dos integrantes, para consulta e eventual adaptação a outros agravos.

O estudo abrange os municípios do Estado de São Paulo entre 25 de fevereiro de 2020 e 18 de novembro de 2023, último dia de atualização diária do repositório da Fundação Seade no GitHub. A partir de 19 de novembro de 2023 os dados passaram a ser atualizados semanalmente no portal da Fundação (FUNDAÇÃO SEADE, 2023). São usados apenas dados agregados por município e por data, sem registros individuais, o que afasta o tratamento de dados pessoais

previsto na Lei Geral de Proteção de Dados (BRASIL, 2018). Como a série está encerrada, a avaliação do detector é retrospectiva: os alertas são comparados com picos já ocorridos. O que se mede é se o método teria sinalizado a elevação antes do pico, e não sua capacidade de prever a evolução futura da epidemia. O trabalho também não propõe modelo epidemiológico do tipo compartimental nem pretende substituir os instrumentos oficiais de vigilância.

2.3 FUNDAMENTAÇÃO TEÓRICA

A Lei nº 12.527/2011 obriga os órgãos públicos à transparência ativa, o que inclui divulgar dados em formato aberto (BRASIL, 2011). Durante a pandemia, essa abertura permitiu o surgimento de painéis e análises independentes. O repositório da Fundação Seade, organizado a partir dos registros da Secretaria de Estado da Saúde, publica a série municipal de casos e óbitos, além de conjuntos sobre leitos, internações e doenças preexistentes, com nota metodológica (FUNDAÇÃO SEADE, 2023).

Laney (2001) descreveu os grandes volumes de dados por três dimensões: volume, velocidade e variedade. A base usada aqui, com cerca de 880 mil linhas e 77 MB, não chega a esse porte. Ela cabe na memória de um computador pessoal e é processada com ferramentas comuns da linguagem Python, como a biblioteca Pandas (McKINNEY, 2010). O requisito de análise de dados em escala da disciplina é atendido pela mudança de escala em relação à aplicação de partida, que passou de cerca de 1,3 mil para 880 mil registros, e pelo processamento automatizado de 645 séries municipais. O formato colunar comprimido (Parquet) reduz o tamanho do arquivo e permite versioná-lo junto ao código.

O aprendizado não supervisionado reúne técnicas que procuram estrutura em dados sem rótulo (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Entre os algoritmos de agrupamento, o k-médias é o mais usado, por ser simples e barato computacionalmente, mas exige definir antes o número de grupos e é sensível à escala das variáveis (JAIN, 2010). Por isso os atributos costumam ser padronizados antes do agrupamento (JAMES et al., 2021), e o número de grupos é avaliado por critérios objetivos. Um deles é o coeficiente de silhueta, que compara, para cada elemento, a distância média aos membros do próprio grupo com a distância média ao grupo vizinho mais próximo. O valor varia de -1 a 1 , e valores próximos de 1 indicam grupos coesos e

bem separados (ROUSSEEUW, 1987). Kaufman e Rousseeuw (1990) leem a silhueta média em faixas: acima de 0,70, estrutura forte; de 0,51 a 0,70, razoável; de 0,26 a 0,50, fraca e possivelmente artificial; até 0,25, ausência de estrutura substancial.

A detecção de anomalias procura observações que se afastam do comportamento esperado de um conjunto de dados (CHANDOLA; BANERJEE; KUMAR, 2009). Em séries temporais, ela não tenta prever o valor futuro: procura o momento em que a série rompe o próprio padrão recente. A ideia vem do controle estatístico de processos, em que os limites saem da média e da dispersão históricas, e um ponto fora deles indica causa especial, e não variação aleatória (MONTGOMERY, 2016). Na vigilância em saúde, essa lógica aparece nos algoritmos do *Early Aberration Reporting System* (EARS), criados pelos *Centers for Disease Control and Prevention* dos Estados Unidos. O valor do dia é comparado com a média e o desvio-padrão de uma janela de referência recente, e o alerta é emitido quando a diferença passa de três desvios-padrão. A variante C2 afasta a janela de referência do dia avaliado, para que o início de um surto não entre no cálculo da própria referência (HUTWAGNER et al., 2003). Unkel et al. (2012) revisam esses e outros métodos estatísticos de detecção de surtos e lembram que a avaliação precisa considerar, ao mesmo tempo, a sensibilidade, a oportunidade dos alertas e a frequência de alarmes falsos.

No Brasil, Cerqueira-Silva et al. (2024) aplicaram as variantes C1, C2 e C3 do EARS a atendimentos por queixas respiratórias na atenção primária, em todo o país, e usaram dados de hospitalização para confirmar as semanas de alerta. A variante C2 teve a maior proporção de alarmes antecipados. Os autores também informam a proporção de alertas verdadeiros de cada variante, medida que este projeto ainda precisa incorporar à sua avaliação.

A literatura brasileira recente apoia duas decisões deste trabalho. A primeira é tratar os municípios separadamente, em vez de analisar o Estado como um todo. Martire Junior et al. (2025) acompanham a incidência, a mortalidade e a letalidade da COVID-19 no Estado de São Paulo entre 2020 e 2023 e mostram que essas medidas mudaram de patamar ao longo do período, com maior incidência em 2021 e queda acentuada em 2023. Chrispim, Pisani e Bando (2024), que estudaram 39 municípios da Região Metropolitana do Vale do Paraíba e Litoral Norte, encontram um padrão de espalhamento que parte dos municípios mais densos e acompanha os eixos rodoviários federais, com variação maior nos municípios menos densos. Municípios vizinhos, portanto, podem ter dinâmicas distintas. A segunda decisão é interpretar

com cuidado as diferenças de letalidade entre municípios. Reis, Poli e Uehara (2024), em estudo ecológico com os municípios paulistas, encontram associação entre indicadores socioeconômicos, como renda, escolaridade e IDH municipal, e as taxas de incidência, mortalidade e letalidade entre idosos. As diferenças entre os grupos obtidos aqui não devem ser lidas apenas como diferenças de gravidade clínica.

Séries diárias de notificação costumam oscilar conforme o dia da semana, porque o registro depende da rotina dos serviços. Uma média móvel de ordem 7 remove esse componente periódico e deixa a tendência visível (HYNDMAN; ATHANASOPOULOS, 2021). Os mesmos autores recomendam avaliar métodos aplicados a séries temporais respeitando a ordem cronológica das observações, sem partição aleatória, já que o valor de um dia depende dos dias anteriores.

Na comunicação dos resultados, Tufte (2001) define a excelência gráfica como transmitir o maior número de ideias no menor tempo, com o menor uso de tinta e no menor espaço, o que desaconselha elementos sem função informativa. Few (2009) acrescenta que a análise visual ganha com a interação: filtrar, ordenar e comparar permite ao usuário formular e verificar hipóteses próprias, algo que um relatório estático não oferece. É também o que pede a disciplina, que exige interface dinâmica em vez de saídas fixas.

O desenvolvimento segue o modelo de referência CRISP-DM, que divide projetos de mineração de dados em seis fases: compreensão do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação (WIRTH; HIPPEL, 2000). Por ser iterativo, ele se ajusta à metodologia da Univesp, organizada nas etapas ouvir, criar e implementar, detalhadas na seção seguinte.

2.4 METODOLOGIA

Quanto à natureza, esta é uma pesquisa aplicada, voltada a um problema concreto. Quanto à abordagem, é quantitativa, porque se apoia em medição e tratamento estatístico de dados secundários. Quanto aos objetivos, é exploratório-descritiva, porque busca caracterizar padrões ainda não sistematizados no contexto estudado (GERHARDT; SILVEIRA, 2009; SEVERINO,

2002). O procedimento técnico é a pesquisa documental, com dados secundários de fonte oficial, complementada por consulta a profissionais da área da saúde. O recorte responde à pergunta da seção 2.2 e se divide em duas frentes: o agrupamento dos municípios e a avaliação retrospectiva do detector de anomalias.

O trabalho segue as três etapas da metodologia da Univesp, que são ouvir e interpretar o contexto, criar e prototipar, implementar e testar, articuladas às fases do CRISP-DM (WIRTH; HIPPE, 2000).

Ouvir e interpretar o contexto

O contexto do projeto são os municípios de origem dos integrantes, no interior do Estado de São Paulo. O público-alvo são gestores e profissionais de vigilância epidemiológica das secretarias municipais de saúde.

A caracterização inicial do problema partiu do registro documental produzido na edição anterior do Projeto Integrador, quando a aplicação foi desenvolvida. Segundo esse registro, o levantamento em portais de prefeituras e em veículos de comunicação regionais apontou a necessidade de monitoramento contínuo e localizado dos contágios. O grupo revisou o documento e o adotou como ponto de partida. Nesta edição ainda não houve contato direto com o público-alvo. Está prevista uma entrevista semiestruturada, cujo roteiro está no Apêndice B, para verificar quais indicadores esses profissionais usam na rotina, com quanta antecedência um aviso de elevação seria útil e se os agrupamentos e alertas apresentados são compreensíveis. O perfil dos participantes, o número de entrevistas e as datas serão informados no relatório final.

Criar e prototipar

A solução é construída em cinco etapas encadeadas, versionadas em repositório público:

- Coleta e conversão: download do arquivo dados_covid_sp.csv do repositório da Fundação Seade e gravação em formato colunar comprimido (Parquet), o que reduz o tempo de carga e permite versionar o dado junto ao código;

- Pré-processamento: exclusão da categoria residual “Ignorado”, que não tem população de referência, ordenação das séries por município e data e padronização de tipos e do separador decimal. As variações diárias negativas do arquivo original vêm de retificações retroativas e se concentram nessa categoria, de modo que a base de trabalho fica sem valores negativos;
- Construção de atributos: cálculo de sete indicadores por município, que são incidência acumulada e mortalidade acumulada por 100 mil habitantes, letalidade aparente (óbitos divididos por casos), altura do maior pico da média móvel por 100 mil habitantes, coeficiente de variação da média móvel de sete dias, proporção dos casos ocorridos até 31/12/2021 e logaritmo da população residente. Como a letalidade é a razão entre mortalidade e incidência, esses três atributos não são independentes, e o efeito dessa redundância sobre os grupos ainda será avaliado;
- Agrupamento: padronização dos atributos por escore z e aplicação do k-médias para k de 2 a 8, com dez inicializações (n_init igual a 10) e semente fixa (random_state igual a 42), o que torna a partição reproduzível. Para cada k calcula-se o coeficiente de silhueta. A escolha de k considera a silhueta, a estabilidade da partição entre execuções com sementes diferentes e a interpretabilidade dos grupos;
- Detecção de anomalias: para cada município e cada dia t, calculam-se a média e o desvio-padrão da média móvel de sete dias nos dias $t-34$ a $t-7$, isto é, em uma janela de 28 dias encerrada uma semana antes do dia avaliado. O alerta é emitido quando a média móvel do dia t supera a média dessa janela em pelo menos três desvios-padrão e é de no mínimo três casos.

Cada parâmetro do detector tem uma função. A janela de 28 dias define o que é o comportamento recente do município. Janelas curtas acompanham melhor as mudanças rápidas de patamar, mas geram estimativas instáveis; janelas longas são mais estáveis e demoram mais a se ajustar. A defasagem de sete dias impede que os primeiros dias de uma subida entrem na própria referência e elevem a média e o desvio-padrão, o que atrasaria o alerta. É o mesmo

princípio da variante C2 do EARS (HUTWAGNER et al., 2003). O limiar de três desvios-padrão corresponde ao limite de controle usual no controle estatístico de processos (MONTGOMERY, 2016). O piso de três casos evita alertas em municípios pequenos, onde um único caso já produziria escore z alto, e o desvio-padrão da janela tem piso de 0,5 caso, o que evita divisões por valores próximos de zero. A média móvel usada é a coluna `casos_mm7d`, publicada pela Fundação Seade; ela é retroativa, isto é, calculada sobre o dia avaliado e os seis anteriores, o que foi conferido reproduzindo a coluna a partir dos casos novos. Nenhum ponto da série usa informação de dias posteriores.

A avaliação do detector é retrospectiva e usa os dados consolidados, e não os dados disponíveis em cada data, que estavam sujeitos a atrasos e retificações. Os picos de cada série são identificados pela função `find_peaks` da biblioteca SciPy (VIRTANEN et al., 2020). São considerados picos os máximos locais cuja proeminência alcança 20% do maior valor da série do município, com mínimo de três casos, e cuja altura alcança 25% desse mesmo máximo, com mínimo de cinco casos. Os limiares são relativos a cada município, o que evita concentrar os picos detectados nas cidades grandes, e se aplicam à série em valores absolutos. Não há distância mínima entre picos consecutivos. Para cada pico, verifica-se se houve alerta nos 60 dias anteriores. São calculadas três medidas: a cobertura, que é a proporção de picos precedidos por ao menos um alerta; a antecedência, em dias, entre o primeiro alerta dessa janela e o pico; e a taxa de alerta, que é a proporção de dias-município com alerta e indica quantos avisos o usuário teria de verificar. A taxa de alerta não equivale à taxa de alarmes falsos, porque um dia com alerta pode corresponder a uma elevação real.

Essas três medidas não bastam para concluir que o método antecipa os picos. Com taxa de alerta próxima de 5% e janela de 60 dias, alertas sem relação com a série também cairiam antes da maioria dos picos, como mostra a seção 2.5. A avaliação será completada com quatro procedimentos: uma linha de base aleatória, obtida pelo deslocamento circular da sequência de alertas de cada município, que mantém o número e o agrupamento dos alertas mas desfaz sua relação temporal com os picos; a precisão, que é a proporção de episódios de alerta seguidos de pico em até 60 dias; a definição de episódio de alerta como sequência de dias com alerta separada da seguinte por pelo menos 14 dias sem alerta; e a análise de sensibilidade para limiares de 2,0 a 4,0 desvios-padrão, já calculada e apresentada na Tabela 4. Os três primeiros ainda não foram executados.

As ferramentas são a linguagem Python, as bibliotecas Pandas, scikit-learn (PEDREGOSA et al., 2011), SciPy (VIRTANEN et al., 2020) e Plotly, o *framework* Streamlit e o sistema de controle de versão Git, com repositório hospedado no GitHub.

Implementar e testar

A verificação tem duas frentes. A primeira é técnica: clonar o repositório em um computador diferente do de desenvolvimento e executar o projeto seguindo apenas as instruções do README, para confirmar que outra pessoa consegue reproduzi-lo. A segunda é a avaliação com usuários: apresentar a versão preliminar a profissionais da área da saúde e aplicar o roteiro do Apêndice B, que verifica a clareza das visualizações, a pertinência dos indicadores e a utilidade percebida dos alertas.

As respostas são registradas em formulário padronizado, organizadas por tema (clareza, pertinência, utilidade e sugestões) e transformadas em uma lista de ajustes priorizados. As devolutivas obtidas e as melhorias decorrentes serão relatadas no relatório final.

2.5 RESULTADOS PRELIMINARES: SOLUÇÃO INICIAL

Esta seção apresenta os resultados obtidos até agora, organizados pelas três etapas da metodologia. Estão concluídos o diagnóstico da aplicação de partida, a auditoria da base de dados e os dois modelos, que já rodam e estão integrados à interface. Estão em desenvolvimento a comparação do detector com uma linha de base aleatória, o tratamento das falhas de notificação e a definição do número de grupos. Falta realizar a avaliação com usuários.

Resultados da etapa ouvir

O registro documental da edição anterior aponta a necessidade de monitoramento contínuo e localizado dos contágios. O grupo reexaminou esse ponto a partir de um diagnóstico técnico da aplicação de partida. A aplicação tinha cinco telas de visualização descritiva, que eram evolução temporal, mapa de calor, curva por cidade, panorama municipal e comparativo entre municípios, construídas sobre quatro arquivos agregados que somam cerca de 1,3 mil registros. O Quadro 1 resume as limitações identificadas e as ações previstas.

Quadro 1 – Limitações identificadas na aplicação de partida e ações previstas no PI IV

Limitação identificada	Implicação	Ação prevista no PI IV
Ausência de técnicas de aprendizado de máquina	A aplicação descreve o passado, sem sintetizar padrões nem sinalizar desvios; não atende à ementa da disciplina	Incorporar agrupamento por k-médias e detecção de anomalias
Uso de subconjuntos agregados, com cerca de 1,3 mil registros em quatro arquivos	Volume incompatível com o requisito de análise de dados em escala	Adotar a série municipal completa, com 880.498 registros
Arquivo de dados principal referenciado no código, mas ausente do repositório	A aplicação não é executável a partir de cópia limpa do repositório	Converter o arquivo para formato colunar comprimido e versioná-lo junto ao código
Caminhos de arquivo em notação do sistema operacional Windows	Impede a execução em ambientes Linux e macOS	Substituir por caminhos relativos, independentes do sistema operacional
Ausência de documentação de execução e de testes	Compromete a reprodutibilidade e a avaliação por terceiros	Publicar instruções de instalação, requisitos de ambiente e licença de uso dos dados
Ausência de validação com usuários finais	Não há evidência de adequação da aplicação ao contexto de uso	Aplicar roteiro de avaliação junto às secretarias municipais de saúde

Fonte: elaborado pelos autores (2026).

O principal resultado desta etapa foi delimitar a distância entre a aplicação disponível e o problema do projeto. A aplicação descrevia a série histórica, mas não resumia as diferenças entre municípios nem sinalizava desvios de comportamento. Ainda não houve escuta direta do público-alvo, prevista para a próxima etapa.

Resultados da etapa criar

A primeira providência foi substituir a base agregada pela série municipal completa. A Tabela 1 apresenta a caracterização do conjunto, obtida por auditoria programática de seus atributos.

Tabela 1 – Caracterização do conjunto de dados dados_covid_sp.csv

Dimensão	Valor observado
Fonte	Secretaria de Estado da Saúde de São Paulo, organização da Fundação Seade
Arquivo	dados_covid_sp.csv
Registros	880.498 no arquivo original; 879.135 após a exclusão da categoria residual
Variáveis	11
Chaves de município	646 (645 municípios e a categoria residual “Ignorado”)
Datas distintas	1.363
Período coberto	25/02/2020 a 18/11/2023
Tamanho em disco	76,9 MB em CSV; cerca de 5,5 MB em Parquet
Valores ausentes declarados	Nenhum
Registros sem população de referência	1.363 (categoria “Ignorado”)
Variações diárias negativas (arquivo original)	772 em casos novos e 475 em óbitos novos
Casos acumulados em 18/11/2023 (base tratada)	6.735.396
Óbitos acumulados em 18/11/2023 (base tratada)	181.853
População de referência (base tratada)	44.639.899

Fonte: elaborado pelos autores a partir de Fundação Seade (2023).

O conjunto não tem valores ausentes declarados, o que não significa ausência de problemas de qualidade. Há 1.363 registros, um por data, atribuídos à categoria residual “Ignorado”, que não tem população de referência e não serve para calcular indicadores por habitante. O arquivo original traz ainda 1.247 variações diárias negativas, sendo 772 em casos novos e 475 em óbitos novos, resultantes de retificações feitas pela fonte. Elas aparecem quando a fonte reclassifica um caso antes sem município, e por isso se concentram na categoria residual. Depois de excluí-la, a base de trabalho tem 879.135 registros, de 645 municípios ao longo de 1.363 datas, e nenhuma variação negativa. A conversão para Parquet reduziu o arquivo de 76,9 MB para cerca de 5,5 MB, o que permite versioná-lo no repositório.

A análise exploratória orientou as decisões de modelagem. A Figura 1 mostra a evolução dos novos casos diários no Estado, suavizada por média móvel de sete dias.

Figura 1 – Novos casos diários de COVID-19 no Estado de São Paulo (média móvel de 7 dias), 2020-2023




Fonte: elaborado pelos autores a partir de Fundação Seade (2023).

A série mostra ao menos quatro ondas de amplitudes diferentes, com queda acentuada a partir de 2023. O maior valor, de 18.202 casos diários em 16 de junho de 2021, está no topo de um platô que se estende pelo mês, com valores próximos de 17,7 mil nos dias seguintes. A curva também tem interrupções seguidas de saltos. Em 16 de setembro de 2021 foram notificados 25.742 casos em um único dia, contra valores entre 450 e 725 nos dias anteriores, e em 30 de dezembro de 2021 foram 4.386 casos depois de uma semana com totais entre 14 e 163. Esses saltos correspondem a notificações represadas e divulgadas de uma vez, e não a mudanças reais na transmissão. A série não é estacionária e muda de patamar com frequência, o que desaconselha limiares fixos e justifica comparar cada dia com o comportamento recente do próprio município.

A Figura 2 relaciona a incidência acumulada e a letalidade aparente dos municípios paulistas na posição de 18 de novembro de 2023.

Figura 2 – Incidência acumulada e letalidade aparente nos municípios paulistas, posição em 18/11/2023




Fonte: elaborado pelos autores a partir de Fundação Seade (2023). Nota: representados os 645 municípios do Estado.

Municípios com menor incidência registrada tendem a apresentar letalidade aparente mais alta. A correlação de Spearman entre as duas medidas é de $-0,77$ ($p < 0,001$), e as medianas são de 18.578 casos por 100 mil habitantes e 2,08%. Parte dessa relação é aritmética, porque a letalidade é a razão entre óbitos e casos: com mortalidade parecida, o município que registra menos casos apresenta letalidade maior. O padrão também combina com diferenças de testagem e de notificação e com desigualdades socioeconômicas já descritas para os municípios paulistas (REIS; POLI; UEHARA, 2024), mas o projeto não tem dados de testagem nem indicadores socioeconômicos para testar essa hipótese. Por isso o agrupamento precisa usar atributos proporcionais à população e padronizados, e não contagens absolutas, que refletiriam sobretudo o porte dos municípios.

Agrupamento dos municípios

Com os sete atributos padronizados por escore z, aplicou-se o k-médias para k de 2 a 8. A Figura 3 mostra o coeficiente de silhueta de cada partição.


Figura 3 – Coeficiente de silhueta segundo o número de agrupamentos



Fonte: elaborado pelos autores (2026).

Os valores ficam entre 0,230 e 0,273, com máximo em $k = 2$ (0,273). Para $k = 4$ o valor é 0,234. Pela leitura de Kaufman e Rousseeuw (1990), as partições com $k = 2$ e $k = 3$ ficam na faixa de estrutura fraca, perto do limite inferior, e as partições de $k = 4$ a $k = 8$ ficam na faixa de ausência de estrutura substancial. Os municípios não se dividem em grupos nitidamente separados: seus perfis variam de forma contínua. A silhueta, sozinha, não indica nenhuma partição como natural, e os grupos devem ser lidos como uma forma de resumir essa variação, não como tipos bem definidos. Para caracterização exploratória, o grupo examinou a partição em quatro grupos, apresentada na Figura 4 e na Tabela 2. O valor de k da versão final será escolhido na próxima etapa, considerando a silhueta, a estabilidade da partição e a interpretabilidade dos grupos.

Figura 4 – Perfil padronizado dos grupos na partição exploratória com k = 4



Fonte: elaborado pelos autores (2026). Nota: médias de cada grupo em escore z, calculado em relação à média dos 645 municípios.

Tabela 2 – Caracterização dos grupos na partição exploratória com k = 4

Grupo	Municípios	População (mediana)	Incidência acumulada por 100 mil	Letalidade aparente	Maior pico (casos/dia por 100 mil)	Casos até 2021
1	181	7.268	9.880	3,83%	146	91%
2	135	110.489	15.305	2,91%	106	73%
3	69	3.731	33.097	1,62%	890	41%
4	260	14.722	25.556	1,62%	296	50%

Fonte: elaborado pelos autores (2026). Nota: incidência, letalidade, altura do pico e proporção de casos até 2021 são médias dos municípios de cada grupo; a população é a mediana do grupo. “Casos até 2021” é a proporção dos casos do município registrados até 31/12/2021.


O Grupo 1 reúne municípios pequenos, com a menor incidência registrada e a maior letalidade aparente, e concentra cerca de 90% dos casos até o fim de 2021. Uma hipótese é a menor capacidade de testagem nesses municípios, que os dados disponíveis não permitem verificar. O Grupo 2 reúne os municípios mais populosos, com curvas mais suaves e a menor variabilidade. O Grupo 3, o menor deles, tem a maior incidência, o maior pico relativo e a maior variabilidade. Sua população mediana é de 3.731 habitantes, e um pico de 890 casos diários por 100 mil equivale a cerca de 33 casos por dia em um município desse porte. Taxas calculadas sobre populações tão pequenas oscilam muito com poucos casos, então parte do que distingue esse

grupo pode ser instabilidade estatística, e não um perfil epidemiológico próprio. O Grupo 4, o mais numeroso, reúne municípios de porte intermediário, com incidência alta, letalidade aparente de 1,62%, igual à do Grupo 3, e casos distribuídos de forma mais equilibrada ao longo do período.

Deteção de anomalias

O detector foi aplicado às 645 séries municipais com os parâmetros descritos na seção 2.4. A Figura 5 mostra seu comportamento no município de Bauru.

Figura 5 – Alertas disparados e picos identificados no município de Bauru, 2020-2023



Fonte: elaborado pelos autores a partir de Fundação Seade (2023).

Em Bauru, o pico de 18 de fevereiro de 2022 foi precedido por um primeiro alerta em 5 de janeiro de 2022, 44 dias antes. A figura mostra também dois comportamentos que afetam as medidas agregadas. Em vários episódios os alertas se concentram no próprio pico ou muito perto dele, quando a elevação já era visível. E, no segundo semestre de 2021, a série fica em zero por algumas semanas e depois salta, e esse salto gera alerta. Nesse caso o detector responde a uma falha de notificação, e não a um surto.

A Tabela 3 consolida o desempenho preliminar sobre o conjunto das séries, e a Tabela 4 mostra como as medidas variam com o limiar.

Tabela 3 – Desempenho preliminar do detector de anomalias (limiar $z = 3,0$)

Medida	Valor obtido
Séries analisadas	645 municípios
Picos identificados	4.307
Picos com alerta nos 60 dias anteriores (cobertura)	94,6%
Antecedência mediana do primeiro alerta	31 dias
Intervalo interquartilico da antecedência	14 a 49 dias
Taxa de alerta	5,41% dos dias-município
Parâmetros	janela de referência de 28 dias, defasagem de 7 dias, limiar de 3 desvios-padrão, piso de 3 casos diários, janela de busca de 60 dias

Fonte: elaborado pelos autores (2026).

Tabela 4 – Sensibilidade das medidas de desempenho ao limiar do detector

Limiar (z)	Cobertura	Antecedência mediana (dias)	Intervalo interquartilico (dias)	Taxa de alerta
2,0	98,1%	35	18 a 54	7,74%
2,5	96,7%	33	16 a 51	6,42%
3,0	94,6%	31	14 a 49	5,41%
3,5	91,3%	30	13 a 47	4,59%
4,0	88,2%	28	11 a 46	3,94%

Fonte: elaborado pelos autores (2026). Nota: demais parâmetros como na Tabela 3.

Com limiar de 3,0, houve alerta nos 60 dias anteriores a 94,6% dos 4.307 picos, com antecedência mediana de 31 dias e intervalo interquartilico de 14 a 49 dias. No mesmo limiar, 5,41% dos dias-município foram sinalizados. Esses números ainda não permitem afirmar que o método antecipa os picos, por três razões.

A primeira é a ausência de linha de base. Se os alertas fossem independentes entre si e distribuídos ao acaso, com a mesma taxa de 5,41%, a chance de ao menos um deles cair nos 60 dias anteriores a um pico seria de cerca de 96% ($1 - 0,9459^{60}$). Os alertas reais ocorrem em sequências, então a linha de base correta é menor, mas precisa ser calculada. A Tabela 4 reforça o argumento: quando o limiar passa de 2,0 para 4,0, a taxa de alerta cai quase pela metade e a cobertura diminui apenas de 98,1% para 88,2%.

A segunda é a forma de medir a antecedência. Ela é contada a partir do primeiro alerta da janela de 60 dias, que pode pertencer a um episódio anterior ao do pico, e não pode passar de 60 dias,

de modo que antecedências maiores ficam truncadas nesse valor. A mediana de 31 dias, perto da metade da janela, é compatível com esse efeito.

A terceira são as falhas de notificação. A base tem 14.903 sequências de sete dias ou mais sem casos registrados, distribuídas por 644 municípios, e em 759 delas houve alerta nos sete dias seguintes ao fim da sequência, o que soma 3.255 alertas, ou 7,0% do total. Em municípios pequenos, semanas sem casos são esperadas, e nem toda sequência indica falha de registro. Ainda assim, parte dos alertas responde ao represamento de notificações, e não a surtos. Soma-se a isso o fato de que o número de picos depende do critério de proeminência adotado. A comparação com a linha de base e a calibração conjunta do limiar, do piso de casos e do critério de pico são a principal tarefa técnica da próxima etapa.

Resultados da etapa implementar

A aplicação do PI IV foi reorganizada em um repositório público novo (<https://github.com/sailerbeatriz/projetointegradorIV>), separado do repositório da edição anterior (<https://github.com/elbrener/covidestadodesp>), preservado como referência. Os problemas apontados no Quadro 1 foram tratados: a base foi convertida para Parquet e versionada junto ao código, e a execução passou a seguir três passos documentados no README, que são instalar as dependências, rodar os três scripts do processamento e iniciar a interface com o Streamlit. O grupo optou por não publicar a aplicação em serviço de nuvem. A distribuição é feita pelo GitHub e a execução é local.

Os dois modelos foram integrados à interface, que tem cinco seções. A seção “Visão geral” traz a série do Estado; “Município” mostra a série de cada cidade com limiar de alerta ajustável; “Agrupamento” apresenta o perfil dos grupos; “Alerta precoce” traz a cobertura em função da taxa de alerta; e “Comparativo” põe dois municípios lado a lado. A aplicação lê os arquivos gerados pelos três scripts, o que mantém separados o processamento e a visualização. Ainda não houve sessões de teste com usuários. A apresentação da versão preliminar a profissionais da área da saúde está prevista para a quinzena seguinte à entrega deste relatório, a partir de uma instalação local conduzida pelos integrantes. A data, o local e os participantes serão informados no relatório final.

REFERÊNCIAS

- BRASIL. Lei nº 12.527, de 18 de novembro de 2011. Regula o acesso a informações previsto no inciso XXXIII do art. 5º da Constituição Federal. Brasília, DF: Presidência da República, 2011.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018.
- CERQUEIRA-SILVA, T. et al. Early warning system using primary health care data in the post-COVID-19 pandemic era: Brazil nationwide case-study. **Cadernos de Saúde Pública**, v. 40, n. 11, p. 1-12, 2024. DOI: 10.1590/0102-311XEN010024.
- CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly detection: a survey. **ACM Computing Surveys**, v. 41, n. 3, art. 15, p. 1-58, 2009.
- CHRISPIM, E. H. S.; PISANI, R. J.; BANDO, D. H. Dinâmica espaço temporal do espalhamento da COVID-19 na Região Metropolitana do Vale do Paraíba e Litoral Norte no Estado de São Paulo entre 2020 e 2021. **Geoambiente On-line**, n. 48, 2024. Disponível em: <https://revistas.ufj.edu.br/geoambiente/article/view/75084>. Acesso em: 23 set. 2026.
- FEW, S. **Now you see it**: simple visualization techniques for quantitative analysis. Oakland: Analytics Press, 2009.
- FUNDAÇÃO SEADE. **Repositório de dados sobre SARS-CoV-2 em municípios paulistas**. São Paulo: Fundação Seade, 2023. Disponível em: <https://github.com/seade-R/dados-covid-sp>. Acesso em: 14 set. 2026.
- GERHARDT, T. E.; SILVEIRA, D. T. (org.). **Métodos de pesquisa**. Porto Alegre: Editora da UFRGS, 2009.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The elements of statistical learning**: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.
- HUTWAGNER, L.; THOMPSON, W.; SEEMAN, G. M.; TREADWELL, T. The bioterrorism preparedness and response Early Aberration Reporting System (EARS). **Journal of Urban Health**, v. 80, supl. 1, p. i89-i96, 2003.
- HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting**: principles and practice. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 23 set. 2026.
- JAIN, A. K. Data clustering: 50 years beyond K-means. **Pattern Recognition Letters**, v. 31, n. 8, p. 651-666, 2010.
- JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An introduction to statistical learning**: with applications in R. 2. ed. New York: Springer, 2021.
- KAUFMAN, L.; ROUSSEUW, P. J. **Finding groups in data**: an introduction to cluster analysis. New York: John Wiley & Sons, 1990.
- LANEY, D. **3D data management**: controlling data volume, velocity and variety. Stamford: META Group, 2001.

MARTIRE JUNIOR, L. J. et al. Evolution of COVID-19 in the State of São Paulo: analysis of incidence, mortality and lethality from 2020 to 2023. **Epidemiologia**, v. 6, n. 1, art. 6, 2025. DOI: 10.3390/epidemiologia6010006.

McKINNEY, W. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings** [...]. Austin: SciPy, 2010. p. 56-61.

MONTGOMERY, D. C. **Introdução ao controle estatístico da qualidade**. 7. ed. Rio de Janeiro: LTC, 2016.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

REIS, T. V. S. dos; POLI, P.; UEHARA, S. C. da S. A. Associação entre taxas de incidência acumulada, mortalidade e letalidade por COVID-19 entre idosos e indicadores socioeconômicos. **Rev Rene**, v. 25, e93712, 2024. DOI: 10.15253/2175-6783.20242593712.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53-65, 1987.

SEVERINO, A. J. **Metodologia do trabalho científico**. 22. ed. rev. e ampl. São Paulo: Cortez, 2002.

TUFTE, E. R. **The visual display of quantitative information**. 2. ed. Cheshire: Graphics Press, 2001.

UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO. **PJI410**: Projeto Integrador em Computação IV: plano de ensino. São Paulo: Univesp, 2026. Disponível em: <https://assets.univesp.br/blackboard/plano-de-ensino/disciplinas/PJI410.html>. Acesso em: 14 set. 2026.

UNKEL, S.; FARRINGTON, C. P.; GARTHWAITE, P. H.; ROBERTSON, C.; ANDREWS, N. Statistical methods for the prospective detection of infectious disease outbreaks: a review. **Journal of the Royal Statistical Society: Series A (Statistics in Society)**, v. 175, n. 1, p. 49-82, 2012.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, n. 3, p. 261-272, 2020.

WIRTH, R.; HIPPI, J. CRISP-DM: towards a standard process model for data mining. In: INTERNATIONAL CONFERENCE ON THE PRACTICAL APPLICATIONS OF KNOWLEDGE DISCOVERY AND DATA MINING, 4., 2000, Manchester. **Proceedings** [...]. Manchester: Practical Application Company, 2000. p. 29-39.

ANEXOS

ANEXO A – Dicionário de variáveis do conjunto dados_covid_sp.csv, divulgado pela Fundação Seade.

Variável	Descrição
nome_munic	Nome do município
codigo_ibge	Código do município no IBGE
datahora	Data de referência (AAAA-MM-DD)
casos	Casos confirmados acumulados
casos_novos	Casos confirmados novos no dia
casos_mm7d	Média móvel de sete dias dos casos novos
obitos	Óbitos acumulados
obitos_novos	Óbitos novos no dia
obitos_mm7d	Média móvel de sete dias dos óbitos novos
pop	População estimada do município
semana_epidem	Semana epidemiológica

Fonte: Fundação Seade (2023).

APÊNDICES

Apêndice A – Repositórios de código do projeto. A versão atual da aplicação, com o processamento dos dados, os scripts de agrupamento e de detecção de anomalias e o código-fonte da interface, está disponível em <https://github.com/sailerbeatriz/projetointegradorIV>. A aplicação de partida, desenvolvida na edição anterior do Projeto Integrador, está disponível em <https://github.com/elbrener/covidestadodesp>.

Apêndice B – Roteiro de entrevista semiestruturada

Objetivo: verificar se os agrupamentos e alertas da aplicação são compreensíveis e úteis na rotina de vigilância e levantar ajustes para a versão final.

Participantes: profissionais da área da saúde com atuação em vigilância epidemiológica ou gestão municipal. O perfil e o número de participantes serão informados no relatório final.

Formato: entrevista individual de 30 a 40 minutos, presencial ou por videoconferência, com demonstração da aplicação. Antes de começar, o entrevistador explica o objetivo acadêmico, garante o anonimato e informa que o participante pode interromper a entrevista a qualquer momento. O participante assina termo de consentimento livre e esclarecido, quando exigido pela disciplina, e autoriza o registro das respostas.

Registro da sessão: cada entrevista anota data, duração, forma de realização (presencial ou videoconferência) e código do participante.

Bloco 1 – Perfil e rotina (antes da demonstração)

1. Qual é a sua função e há quanto tempo atua nela?
2. Que dados e indicadores você usa para acompanhar doenças transmissíveis no município?
Com que frequência?
3. Quando há aumento de casos, como ele costuma ser percebido e comunicado? Quanto tempo isso leva, em geral?
4. Com quanta antecedência um aviso de elevação precisaria chegar para permitir alguma ação, como remanejar equipes, reservar leitos ou intensificar a busca ativa?

Bloco 2 – Leitura da tela (após a demonstração)

5. Olhando esta tela, o que aconteceu neste município nas últimas semanas? Em que momento você teria agido?

Bloco 3 – Agrupamentos

6. A comparação do município com outros do mesmo grupo faz sentido para você? Os grupos parecem reconhecíveis?

7. Que informação ajudaria a entender por que o município está naquele grupo?

Bloco 4 – Alertas

8. O que você entende quando o gráfico mostra um dia com alerta?

9. No exemplo apresentado, a quantidade de alertas parece adequada, excessiva ou insuficiente?

10. Quantos alertas sem aumento real correspondente seriam toleráveis antes de a ferramenta perder credibilidade?

11. Um alerta que aparece quando a subida já é visível no gráfico ainda seria útil? Por quê?

Bloco 5 – Interface e uso

12. Quais telas ou filtros você usaria? Quais parecem desnecessários?

13. Algum termo, cor ou gráfico foi difícil de entender?

14. Você usaria uma ferramenta como esta se ela fosse aplicada a agravos com dados atualizados, como dengue ou síndromes respiratórias? O que faltaria?

CrITÉRIOS DE AVALIAÇÃO: ao final, o participante indica seu grau de concordância, de 1 (discordo totalmente) a 5 (concordo totalmente), com quatro afirmações: “As visualizações são fáceis de

entender”; “Os indicadores são pertinentes à minha rotina”; “Os alertas ajudariam a antecipar ações”; “Consigo usar a aplicação sem ajuda”.

Registro e uso das respostas: as respostas são lançadas em planilha, com uma linha por entrevista e uma coluna por pergunta. As respostas abertas são agrupadas por tema, e cada sugestão é classificada como ajuste de interface, ajuste de método ou fora do escopo. Os ajustes de interface e de método são priorizados pela frequência com que aparecem e pelo esforço de implementação. O relatório final informa quais foram realizados e quais não foram, com a justificativa.